


第8章 数值优化



目 录

- 单变量函数的极小值
- 内德-米德方法（单纯形法）
- 最速下降法（梯度方法）
- 牛顿方法




8.1 单变量函数的极小值

○定义8.1 如果存在包含 p 的开区间 I ,
使得对所有 $x \in I$, 有 $f(p) \leq f(x)$, 则称函数 f 在 $x=p$ 处有
局部极小值。 类似地,

如果对所有 $x \in I$, 有 $f(p) \geq f(x)$, 则称函数 f 在 $x=p$ 处有
局部极大值。

如果 f 在点 $x=p$ 处有局部极大值或极小值, 则称 f 在点
 $x=p$ 处有局部极值。



单调性的定义和判定

- 定义8.2 设 $f(x)$ 定义在区间 I 上。
 - 若对所有 $x_1 < x_2$, 当 $x_1, x_2 \in I$ 时有 $f(x_1) < f(x_2)$, 则称 f 在区间 I 上**递增**。
 - 若对所有 $x_1 < x_2$, 当 $x_1, x_2 \in I$ 时有 $f(x_1) > f(x_2)$, 则称 f 在区间 I 上**递减**。



单调性的定义和判定

- 定理8.1 设 $f(x)$ 在区间 $I=[a,b]$ 上连续, 并在 (a,b) 上可微.
 - 若对所有 $x \in (a,b)$ 有 $f'(x) > 0$, 则 $f(x)$ 在 I 上递增。
 - 若对所有 $x \in (a,b)$ 有 $f'(x) < 0$, 则 $f(x)$ 在 I 上递减。




驻点和一阶导数测试

- 定理8.2 设 $f(x)$ 定义在区间 $I=[a, b]$ 上, 并在内点 $p \in (a, b)$ 处有局部极值。若 $f(x)$ 在 $x=p$ 处可微,

$$\text{则 } f'(p)=0。$$

- 定理8.3 设 $f(x)$ 在 $I=[a, b]$ 上连续, 并设除 $x=p$ 处外, $f'(x)$ 对所有 $x \in (a, b)$ 都有定义。

- 若在 (a, p) 上 $f'(x) < 0$, 而在 (p, b) 上 $f'(x) > 0$,
则 $f(p)$ 是局部极小值。
- 若在 (a, p) 上 $f'(x) > 0$, 而在 (p, b) 上 $f'(x) < 0$,
则 $f(p)$ 是局部极大值。



二阶导数测试

- 定理8.4 设 f 在区间 $[a, b]$ 上连续, 并且 f' 和 f'' 在区间 (a, b) 上有定义。又设 $p \in (a, b)$ 是关键点, 即 $f'(p)=0$ 。
 - 若 $f''(p)>0$, 则 $f(p)$ 是 f 的一个局部极小值。
 - 若 $f''(p)<0$, 则 $f(p)$ 是 f 的一个局部极大值。
 - 若 $f''(p)=0$, 则结果不确定。



8.1.1 分类搜索方法

- 直接法是一种数值方法

基本思想: 迭代, 通过迭代产生一个点序列 $\{X^{(k)}\}$, 使之逐步接近最优点

- 只用到目标函数, 通过对函数多次求值来求函数 $f(x)$ 在给定区间上的一个局部极小值


- 要尽量减少函数求值的次数, 确定在哪里求 $f(x)$ 值的好策略非常重要

- 如黄金分割搜索法、Fibonacci搜索法、
随机搜索法



搜索法必须满足的条件

- 使用这些方法来求 $f(x)$ 的极小值必须满足**特定**的条件，以保证在给定的区间内有合适的极小值
- 这个特定条件就是：函数 $f(x)$ 在给定区间中是**单峰**的
- 定义8.3 如果存在唯一的 $p \in I$ ，使得
 - (1) $f(x)$ 在 $[a, p]$ 上递减，
 - (2) $f(x)$ 在 $[p, b]$ 上递增，则函数 $f(x)$ 在 $I=[a, b]$ 上是（**下**）**单峰**的。



黄金分割搜索法（0.618法）

- 如果已知 $f(x)$ 在 $[a,b]$ 上是（下）单峰的，则有可能找到该区间的一个子区间， $f(x)$ 在该子区间上取得极小值
- 选择两个内点 $c < d$ ，这样就有 $a < c < d < b$ 。


$f(x)$ 的单峰特性保证了：

函数值 $f(c)$ 和 $f(d)$ 小于 $\max\{f(a), f(b)\}$


- 出现两种情况：



黄金分割搜索方法的决策过程



如果 $f(c) \leq f(d)$, 则从右侧压缩, 使用 $[a, d]$



如果 $f(c) > f(d)$, 则从左侧压缩, 使用 $[c, b]$

黄金分割法原理

设函数 $f(x)$ 在闭区间 $[a, b]$ 上是（下）单峰函数，

即在 (a, b) 内 $f(x)$ 有唯一的极小点 p .


在 p 的左边 $f(x)$ 严格单调下降

在 p 的右边 $f(x)$ 严格单调上升

那么对于 (a, b) 内任意两点 $c < d$,

如果 $f(c) < f(d)$, 则 $p \in [a, d]$;

否则 $p \in [c, b]$




黄金分割法

- 选择内点 c 和 d ，使得区间 $[a,c]$ 与 $[d,b]$ 对称，

即 $b-d=c-a$ ，其中 $c=a+(1-r)(b-a)=ra+(1-r)b$


$$d=b-(1-r)(b-a)=(1-r)a+rb$$

并且 $1/2 < r < 1$ （保证 $c < d$ ）



黄金分割法

- 希望 r 在每个子区间上保持为常数，且旧的内点中有一个成为新子区间的一个内点，而另一个则成为新子区间的一个端点




- 在每次迭代中只需要找一个新的点，则只需要一次新的函数求值计算




比例因子的选择

设 $f(c_0) \leq f(d_0)$ ，则从右侧压缩，使用 $[a_0, d_0]$ ，

即取 $a_1 = a_0$ ， $b_1 = d_0$ 和 $d_1 = c_0$ ，则需要再求一个新的点 c_1




因为 $1/2 < r < 1$ （保证 $c < d$ ）




希望：1, r 在每个区间上为常数

2, 旧的内点中的一个为新的子区间的内点

另一个为新的子区间的一个端点



从右侧压缩, 新区间 $[0, r]$



从左侧压缩, 新区间 $[1-r, 1]$

因此：1， 每次迭代中只需要找一个新的点

2， 只需要一次新的函数求值计算

假设： $f(c) \leq f(d)$, 且只进行一次新的函数求值， 则有


$$\frac{d-a}{b-a} = \frac{c-a}{d-a}$$

$$\frac{r(b-a)}{b-a} = \frac{(1-r)(b-a)}{r(b-a)}$$

$$\frac{r}{1} = \frac{1-r}{r}$$

$$r^2 + r - 1 = 0$$

$$r = \frac{-1 \pm \sqrt{5}}{2} \approx 0.618$$



黄金分割比


例:利用黄金分割法求单峰函数

$f(x)=x^2-\sin(x)$ 在 $[0,1]$ 上的极小值

解: 令: $a_0 = 0, b_0 = 1$

$$c_0 = 0 + (1 - \frac{-1 + \sqrt{5}}{2})(1 - 0) = \frac{3 - \sqrt{5}}{2} \approx 0.38919660$$

$$d_0 = 1 - (1 - \frac{-1 + \sqrt{5}}{2})(1 - 0) = \frac{-1 + \sqrt{5}}{2} \approx 0.6180340$$


$$f(c_0) = -0.22684748, \quad f(d_0) = -0.19746793$$

所以有 $f(c_0) < f(d_0)$

所以新的子区间为:

$$[a_0, d_0] = [0.00000000, 0.6180340]$$


$$\text{令: } a_1 = a_0, b_0 = d_0, d_1 = c_0$$

$$c_1 = a_1 + (1-r)(b_1 - a_1)$$

$$= 0 + \left(1 - \frac{-1 + \sqrt{5}}{2}\right)(0.6180340 - 0) \approx 0.2360680$$

计算 $f(c_1)$ 、 $f(d_1)$ 并比较，确定新的子空间，继续迭代，结果如表8.2



结果。

表 8.2 求 $f(x) = x^2 - \sin(x)$ 的极小值的黄金分割搜索法

k	a_k	c_k	d_k	b_k	$f(c_k)$	$f(d_k)$
0	0.0000000	0.3819660	<u>0.6180340</u>	1	-0.22684748	-0.19746793
1	0.0000000	<u>0.2360680</u>	0.3819660	0.6180340	-0.17815339	-0.22684748
2	0.2360680	0.3819660	0.4721360	0.6180340	-0.22684748	-0.23187724
3	0.3819660	0.4721360	<u>0.5278640</u>	0.6180340	-0.23187724	-0.22504882
4	0.3819660	0.4376941	<u>0.4721360</u>	0.5278640	-0.23227594	-0.23187724
5	0.3819660	<u>0.4164079</u>	0.4376941	0.4721360	-0.23108238	-0.23227594
6	0.4164079	<u>0.4376941</u>	0.4508497	0.4721360	-0.23227594	-0.23246503
\vdots	\vdots	\vdots	\vdots	\vdots	\vdots	\vdots
21	0.4501574	<u>0.4501730</u>	0.4501827	0.4501983	-0.23246558	-0.23246558
22	0.4501730	<u>0.4501827</u>	0.4501886	0.4501983	-0.23246558	-0.23246558
23	0.4501827	<u>0.4501886</u>	0.4501923	0.4501983	-0.23246558	-0.23246558

在第 23 次迭代时, 区间收缩为 $[a_{23}, b_{23}] = [0.4501827, 0.4501983]$ 。该区间的宽度为 0.0000156。而在该区间的两个端点处求得的函数值在小数点后有 8 位相同, 即 $f(a_{23}) \approx -0.23246558 \approx f(b_{23})$, 因此算法结束。搜索法的一个问题是, 函数在极小值附近可能比较平缓, 从而限制了精度。割线方法能够求得更精确的解 $p_5 = 0.4501836$ 。

尽管本例中黄金分割搜索法的速度较慢, 但它的优点是可用于 $f(x)$ 不可微的情况。 ■

目 录

- 单变量函数的极小值
- 内德-米德方法（单纯形法）
- 最速下降法（梯度方法）
- 牛顿方法



多元函数求极值的问题

设函数 $f(x_1, x_2, \dots, x_N)$ 定义在区域

$$R = \left\{ (x_1, x_2, \dots, x_N) : \sum_{k=1}^N (x_k - p_k)^2 < r^2 \right\}$$

如果 $f(p_1, p_2, \dots, p_N) \leq f(x_1, x_2, \dots, x_N)$ 对所有的点 $(x_1, x_2, \dots, x_N) \in R$ 都成立，则函数 $f(x_1, x_2, \dots, x_N)$ 在点 (p_1, p_2, \dots, p_N) 处有局部极小值；

如果 $f(p_1, p_2, \dots, p_N) \geq f(x_1, x_2, \dots, x_N)$ 对所有的点 $(x_1, x_2, \dots, x_N) \in R$ 都成立，则函数 $f(x_1, x_2, \dots, x_N)$ 在点 (p_1, p_2, \dots, p_N) 处有局部极大值。



多元函数的极小值问题

- 二元函数的图形是一个几何表面

- 定理8.5（二阶偏导数测试）

设 $f(x,y)$ 及其一阶和二阶偏导数在区域 R 上连续。

设点 $(p,q) \in R$ 是一个临界点，即：

$$f_x(p,q)=0 \text{ 且 } f_y(p,q)=0。$$

可用高阶偏导数来确定临界点的属性。



1, 若 $f_{xx}(p, q)f_{yy}(p, q) - f_{xy}^2(p, q) > 0$ 且 $f_{xx}(p, q) > 0$,

则 $f(p, q)$ 是 f 的局部极小值。

2, 若 $f_{xx}(p, q)f_{yy}(p, q) - f_{xy}^2(p, q) > 0$ 且 $f_{xx}(p, q) < 0$,

则 $f(p, q)$ 是 f 的局部极大值。

3, 若 $f_{xx}(p, q)f_{yy}(p, q) - f_{xy}^2(p, q) < 0$

则 $f(x, y)$ 在 (p, q) 没有局部极值。

4, 若 $f_{xx}(p, q)f_{yy}(p, q) - f_{xy}^2(p, q) = 0$, 则结果不确定。

例8.5

例8.5 求函数 $f(x,y)=x^2-4x+y^2-y-xy$ 的极小值

解: $f_x(x,y)=2x-4-y, f_y(x,y)=2y-1-x$

$$\text{令: } \begin{cases} f_x(x,y)=0 \\ f_y(x,y)=0 \end{cases} \Rightarrow \begin{cases} 2x-y=4 \\ -x+2y=1 \end{cases}$$

$\Rightarrow (x,y)=(3,2), f(x,y)$ 的二阶偏导:

$$f_{xx}(x,y)=2, f_{yy}(x,y)=2, f_{xy}(x,y)=-1$$

可得为定理8.5中的第一种情况, 即

$$f_{xx}(3,2)f_{yy}(3,2)-f_{xy}^2(3,2)=3>0, f_{xx}(3,2)=2>0$$

所以 $f(x,y)$ 在 $(3,2)$ 有局部极小值 $f(3,2)=-7$

多元函数的直接搜索法

- 多变量目标函数 $f(x_1, x_2, \dots, x_N)$ 的极值直接搜索法:

对函数的可微性不作显性或隐性的假设

- 对非光滑（不可微）目标函数而言，直接方法特别有用内德一米德方法(单纯形方法)和鲍威尔方法



单纯形方法的基本思想

- 内德和米德提出了单纯形法，可用于求解多变量函数的局部极小值
- 从可行域中的一个基本可行解出发，判断它是否已是最优解，若不是，寻找下一个基本可行解，并使目标函数得到改进，如此迭代下去，直到找出最优解或判定问题无解为止。
- 从另一个角度说，就是从可行域的某一个极点出发，迭代到另一个极点，并使目标函数的值有所改善，直到找出有无最优解时为止。

单纯形的概念

- 单纯形是指0维中的点，一维中的线段，二维中的三角形，三维中的四面体， n 维空间中的有 $n+1$ 个顶点的多面体。

例如在三维空间中的四面体，其顶点分别为：

$(0,0,0)$ ， $(1,0,0)$ ， $(0,1,0)$ ， $(0,0,1)$ 。

具有单位截距的单纯形的方程是 $\sum x_i \leq 1$ ，

并且 $x_i \geq 0$ ， $i=1,2,\dots,n$



二元函数的单纯形方法

- 在二维平面空间中，单纯形就是三角形
- 搜索过程：

比较三角形3个顶点处的函数值， $f(x,y)$ 值最大的顶点为最差顶点(W)，用一个新的顶点代替最差顶点，形成新的三角形式

- 继续这一过程，生成一系列三角形（它们可能具有不同的形状），函数在其顶点处的值越来越小
- 随着三角形的减小就可以找到极小值点的坐标



单纯形的寻找过程

- ① 初始三角形**BGW**
- ② 良边的中点
- ③ 反射点**R**
- ④ 开拓点**E**
- ⑤ 收缩点**C**
- ⑥ 向**B**方向收缩




单纯形的寻找过程

例：求 $f(x, y)$ 极小值

① 初始三角形BGW

➤ 给定三角形三个顶点 $V_k = (x_k, y_k), k = 1, 2, 3$

➤ 求值： $z_k = f(x_k, y_k), k = 1, 2, 3$



下标满足

$$z_1 \leq z_2 \leq z_3$$

$B(x_1, y_1),$

$G(x_2, y_2),$

$W(x_3, y_3)$

B:最佳顶点

G:次最佳顶点

W:最差顶点



单纯形的寻找过程

例：求 $f(x, y)$ 极小值

① 初始三角形BGW

② 良边的中点


W:Z₃

G:Z₂

M: BG的中点

$$z_1 \leq z_2 \leq z_3$$

$$M = \frac{B + G}{2} = \left(\frac{x_1 + x_2}{2}, \frac{y_1 + y_2}{2} \right)$$



单纯形的寻找过程

① 初始三角形BGW

② 良边的中点

③ 反射点R


$W \rightarrow B$ 方向：值递减

$W \rightarrow G$ 方向：值递减

所以：

以BG连线为分界线，与W相对的点函数值 $f(x,y)$ 较小
选择：

测试点R：关于边 \overline{BG} 对三角形进行“反射”





如何确定反射点R?

- 1, 找到中点M
- 2, 从W到M画线段, 长度为d
- 3, 从M做线段延长线, 长度为d, 得到R

R的向量公式为:

$$R = M + (M - W)$$





点E 沿着连结M和R的线段方向延长距离d

如果 $f_E < f_R$,则改点比R好。 点E的向量公式为:

$$E = R + (R - M) = 2R - M$$




① 初始三角形BGW

② 良边的中点

③ 反射点R

④ 开拓点E

⑤ 收缩点C



如果 $f_R = f_W$, 则需要测试另外的点 (也许M函数值小)


为了保证构成三角形,


不能取M代替W,

分别考虑

$\overline{WM} : C_1$

$\overline{MR} : C_2$






$$f_c = \min(f_{C_1}, f_{C_2})$$

具有较小函数值的为C,并由此构成三角形BGC

- ① 初始三角形BGW
- ② 良边的中点
- ③ 反射点R
- ④ 开拓点E
- ⑤ 收缩点C




⑥ 向B方向收缩

如果: $f_c \geq f_w$

则: G、W必向B收缩

G替换为: M

W替换为: S



S为连接B和W的线段中点

每一步的逻辑判断

■ 若 $f(R) < f(G)$ ，则转①（反射点或开拓点）

否则转②（压缩点或收缩点）

①若 $f(B) < f(R)$ ，则以 R 代替 W

否则计算 E 和 $f(E)$

若 $f(E) < f(B)$ ，则以 E 代替 W

否则以 R 代替 W

例8.6

②若 $f(R) < f(W)$ ，则以 R 代替 W

否则计算 $C_1 = (M+R)/2$ 和 $f(C_1)$

计算 $C_2 = (W+M)/2$ 和 $f(C_2)$

取两者中函数值较小者为 C

若 $f(C) < f(W)$ ，则以 C 代替 W

否则计算 $S = (W+B)/2$ 和 $f(S)$

以 S 代替 W ，以 M 代替 G

例如：8.6 利用单纯形法求

$$f(x, y) = x^2 - 4x + y^2 - y - xy \text{ 的极小值}$$

从以下三个顶点开始：

$$V_1 = (0, 0), V_2 = (1.2, 0.0), V_3 = (0.0, 0.8)$$

解： $f(x, y)$ 在顶点处的值为：

$$f(0, 0) = 0.0, f(1.2, 0.0) = -3.36, f(0.0, 0.8) = -0.16$$

比较三个顶点的值，确定B, G, W：

$$B = (1.2, 0.0), G = (0.0, 0.8), W = (0, 0)$$

所以顶点 $W = (0, 0)$ 将被替代



点 M 和 R 为:

$$M = \frac{B + G}{2} = (0.6, 0.4), R = 2M - W = (1.2, 0.8)$$

$$f(R) = f(1.2, 0.8) = -4.48 < f(G)$$

属于第一种情况

因为: $f(R) \leq f(B)$, 所以移动方向正确
所以:

$$E = 2R - M = 2(1.2, 0.8) - (0.6, 0.4) = (1.8, 1.2)$$

$$f(E) = f(1.8, 1.2) = -5.88 < f(B)$$

所以新三角形顶点为:

$$V_1 = (1.8, 1.2), V_2 = (1.2, 0.0), V_3 = (0.0, 0.8)$$



构造。函数值 $f(B) = -6.99999998$ 。

$$V_1 = (1.8, 1.2), \quad V_2 = (1.2, 0.0),$$

继续该过程, 得到朝着解点 $(3, 2)$ 收敛的一系列三角形 (见图 8.10)。表 8.6 给出了迭代中各步的三角形顶点处的函数值。计算机实现的算法执行到第 33 步, 得到的最佳顶点为 $B = (2.99996456, 1.99983839)$, 函数值为 $f(B) = -6.99999998$ 。它是例 8.5 中求得的 $f(3, 2) = -7$ 的近似值。迭代在到达 $(3, 2)$ 之前停止的原因是, 函数在极小值点附近平缓。经过检查 (见表 8.6), 函数值 $f(B)$, $f(G)$ 和 $f(W)$ (见表 8.6) 相同 (这是舍入误差的一个例子), 算法终止。

表 8.6 例 8.6 中各三角形顶点处的函数值

k	最佳点	较好点	最差点
1	$f(1.2, 0.0) = -3.36$	$f(0.0, 0.8) = -0.16$	$f(0.0, 0.0) = 0.00$
2	$f(1.8, 1.2) = -5.88$	$f(1.2, 0.0) = -3.36$	$f(0.0, 0.8) = -0.16$
3	$f(1.8, 1.2) = -5.88$	$f(3.0, 0.4) = -4.44$	$f(1.2, 0.0) = -3.36$
4	$f(3.6, 1.6) = -6.24$	$f(1.8, 1.2) = -5.88$	$f(3.0, 0.4) = -4.44$
5	$f(3.6, 1.6) = -6.24$	$f(2.4, 2.4) = -6.24$	$f(1.8, 1.2) = -5.88$
6	$f(2.4, 1.6) = -6.72$	$f(3.6, 1.6) = -6.24$	$f(2.4, 2.4) = -6.24$
7	$f(3.0, 1.8) = -6.96$	$f(2.4, 1.6) = -6.72$	$f(2.4, 2.4) = -6.24$
8	$f(3.0, 1.8) = -6.96$	$f(2.55, 2.05) = -6.7725$	$f(2.4, 1.6) = -6.72$
9	$f(3.0, 1.8) = -6.96$	$f(3.15, 2.25) = -6.9525$	$f(2.55, 2.05) = -6.7725$
10	$f(3.0, 1.8) = -6.96$	$f(2.8125, 2.0375) = -6.95640625$	$f(3.15, 2.25) = -6.9525$

目 录

- 单变量函数的极小值
- 内德-米德方法（单纯形法）
- 最速下降法（梯度方法）
- 牛顿方法



梯度方法和牛顿方法

- 内德一米德方法（单纯形法）：

针对多元函数偏导数不可求的方法，是直接搜索法

- 梯度方法和牛顿方法：

针对函数 $f(X)$ 的偏导数可得的求极小值的方法，

其中， $X=(x_1, x_2, \dots, x_N)^T$



梯度的定义

定义8.4

设 $z = f(X)$ 是 X 的函数, 对 $k = 1, 2, \dots, N$,

$\partial f(X) / \partial x_k$ 存在。 f 的**梯度**, 记为 $\nabla f(X)$, 是向量

$$\nabla f(X) = \left(\frac{\partial f(X)}{\partial x_1}, \frac{\partial f(X)}{\partial x_2}, \dots, \frac{\partial f(X)}{\partial x_N} \right)^T$$

■ **梯度向量**在局部指向 $f(X)$ 增加得最快的方向。

因此 **$-\nabla f(X)$** 在局部指向下降得最快的方向。●

关于函数梯度的说明

- 梯度是一个向量。 N 元函数 $f(x_1, x_2, \dots, x_N)$ 在某点 x 处的梯度为：

$$\left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \dots, \frac{\partial f}{\partial x_N} \right)^T$$

- 梯度的方向与函数 f 的等值线的一个法线方向相同，从较低的等值线指向较高的等值线。

- 梯度的方向：函数 f 的值**增加最快**的方向，

其相反方向：函数 f 的值**降低最快**的方向。



梯度法的定义

- 梯度法又称**最速下降法**（**steepest descent method**）
- 由法国数学家**Cauchy**于**1847**年首先提出。

在每次迭代中，

沿最速下降方向（**负梯度方向**）进行搜索，

每步沿**负梯度方向**取最优步长，

因此这种方法称为**最优梯度法**。



梯度方法描述

- 从迭代初始点 P_0 开始，沿着过 P_0 ，方向为：

$$S_0 = \frac{-\nabla f(P_0)}{\|-\nabla f(P_0)\|}$$

的直线搜索，到达点 P_1 .

当点 X 满足约束 $X=P_0+\gamma S_0$ 时，在该点取得局部极小值

- 由于偏导数可得，因此极小化过程可以使用二次或三次近似方法

梯度方法描述

- 然后计算 $-\nabla f(P_1)$ ，并沿方向：
$$S_1 = \frac{-\nabla f(P_1)}{\|-\nabla f(P_1)\|}$$

搜索，到达点 P_2 。


当 X 满足约束 $X=P_1+\gamma S_1$ 时，在该点取得局部极小值

- 迭代该计算过程，得到点序列 $\{P_k\}_{k=0}^{\infty}$ ，

满足 $f(P_0) > f(P_1) > \dots > f(P_k) > \dots$

如果 $\lim_{k \rightarrow \infty} P_k = P$ ，则 $f(P)$ 是 $f(X)$ 的一个局部极小值

梯度法搜索过程示意图



梯度方法概要

□ 设 P_k 已知

■ 求梯度向量 $\nabla f(P_k)$

■ 计算搜索方向
$$S_k = \frac{-\nabla f(P_k)}{\|-\nabla f(P_k)\|}$$

■ 在区间 $[0, b]$ 上对 $\Phi(\gamma) = f(P_k + \gamma S_k)$ 进行单参数极小化， b 为一个较大值。这一过程将产生值 $\gamma = h_{\min}$ ，它是 $\Phi(\gamma)$ 的一个局部极小值点。

关系式 $\Phi(h_{\min}) = f(P_k + h_{\min} S_k)$ 表明，

它是 $f(X)$ 沿搜索线 $X = P_k + h_{\min} S_k$ 的一个极小值



梯度方法概要

- 构造下一个点 $P_{k+1} = P_k + h_{\min} S_k$


- 进行极小化过程的终止判断,

若函数值满足 $|f(P_{k+1}) - f(P_k)| < \varepsilon$

或


两点距离满足 $\|P_{k+1} - P_k\| < \varepsilon$, 则迭代终止,

否则转第①步



例8.9 用梯度法求函数 $f(x, y) = \frac{x - y}{x^2 + y^2 + 2}$ 的 P_1 和 P_2 。

初始点采用 $P_0 = (-3, -2)$



重复该过程。

例 8.9 用梯度法求函数 $f(x, y) = \frac{x-y}{x^2+y^2+2}$ 的 P_1 和 P_2 。初始点采用 $P_0 = (-3, -2)$ 。

解: 当 $P_0 = (-3, -2)$ 时,

$$\begin{aligned} S_0 &= \frac{1}{\|-\nabla f(P_0)\|} (-\nabla f(P_0)) \\ &= \frac{1}{\|-\nabla f(-3, -2)\|} (-\nabla f(-3, -2)) \\ &= (-0.4280863, 0.9037378) \end{aligned}$$

函数

$$\begin{aligned} f(P_0 + \gamma S_0) &= f((-3, -2) + \gamma(-0.4280863, 0.9037378)) \\ &= f(-3 - 0.4280863\gamma, -2 + 0.9037378\gamma) \\ &= \frac{(-3 - 0.4280863\gamma) - (-2 + 0.9037378\gamma)}{(-3 - 0.4280863\gamma)^2 + (-2 + 0.9037378\gamma)^2 + 2} \end{aligned}$$

在 $\gamma = h_{\min_0} = 4.8186760$ 处有极小值(见程序 8.3, 二次插值)。因此

$$\begin{aligned} P_1 &= P_0 + h_{\min_0} S_0 \\ &= (-3, -2) + 4.8186760(-0.4280863, 0.9037378) \\ &= (-5.0628094, 2.3548199) \end{aligned}$$

函数

$$\begin{aligned}f(P_0 + \gamma S_0) &= f((-3, -2) + \gamma(-0.4280863, 0.9037378)) \\&= f(-3 - 0.4280863\gamma, -2 + 0.9037378\gamma) \\&= \frac{(-3 - 0.4280863\gamma) - (-2 + 0.9037378\gamma)}{(-3 - 0.4280863\gamma)^2 + (-2 + 0.9037378\gamma)^2 + 2}\end{aligned}$$

在 $\gamma = h_{min_0} = 4.8186760$ 处有极小值(见程序 8.3, 二次插值)。因此

$$\begin{aligned}P_1 &= P_0 + h_{min_0} S_0 \\&= (-3, -2) + 4.8186760(-0.4280863, 0.9037378) \\&= (-5.0628094, 2.3548199)\end{aligned}$$

当 $P_1 = (-5.0628094, 2.3548199)$ 时,

$$\begin{aligned}S_1 &= \frac{1}{\| -\nabla f(P_1) \|} (-\nabla f(P_1)) \\&= \frac{1}{\| -\nabla f(-5.0628094, 2.3548199) \|} (-\nabla f(-5.0628094, 2.3548199)) \\&= (0.9991231, -0.0418690)\end{aligned}$$

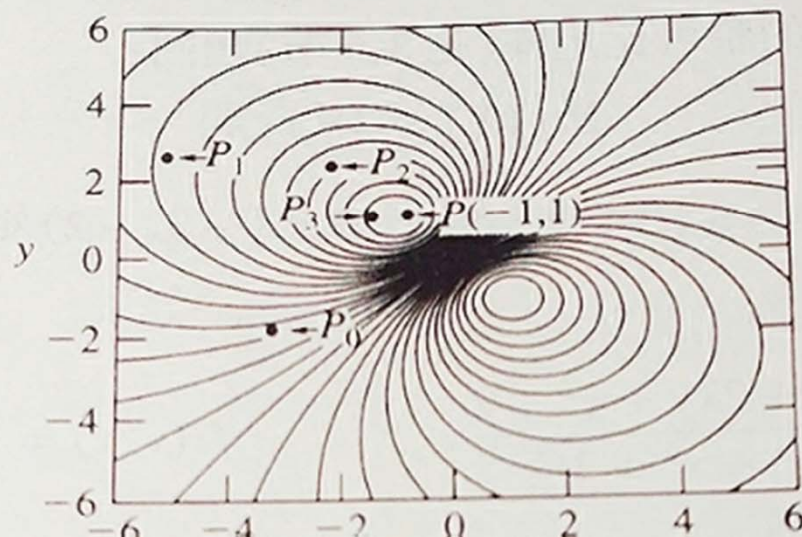
函数

$$\begin{aligned}
 f(P_1 + \gamma S_1) &= f((-5.0628094, 2.3548199) + \gamma(0.9991231, -0.0418690)) \\
 &= f(-5.0628094 + 0.9991231\gamma, 2.3545199 - 0.0418690\gamma) \\
 &= \frac{(-5.0628094 + 0.9991231\gamma) - (2.3545199 - 0.0418690\gamma)}{(-5.0628094 + 0.9991231\gamma)^2 + (2.3545199 - 0.0418690\gamma)^2 + 2}
 \end{aligned}$$

在 $\gamma = h_{\min_1} = 2.7708281$ 处有极小值(见程序 8.3, 二次插值)。因此

$$\begin{aligned}
 P_2 &= P_1 + h_{\min_1} S_0 \\
 &= (-5.0628094, 2.3548199) + 2.7708281(0.9991231, -0.0418690) \\
 &= (-2.2944111, 2.2388080)
 \end{aligned}$$

函数 $f(x, y) = (x - y)/(x^2 + y^2 + 2)$ 在 $P = (-1, 1)$ 处有相对极小值。图 8.13 显示了函数 f 的一个等值线图, 以及点 P_0, P_1, P_2 和 P 的相对位置。表 8.7 中列出了更多的计算结果。



初始点: $P_0=(-3, -2)$




表 8.7 函数 $f(x, y) = (x - y)/(x^2 + y^2 + 2)$ 的梯度方法

k	x_k	y_k	$f(x_k, y_k)$
0	-3.0000000	-2.0000000	-0.0666667
1	-5.0628094	2.3548199	-0.2235760
2	-2.2944111	2.2388080	-0.3692574
3	-1.3879337	1.3859313	-0.4743948
4	-1.0726050	1.0724933	-0.4987762
5	-1.0035351	1.0035334	-0.4999969
6	-1.0000091	1.0000091	-0.5000000
7	-1.0000000	1.0000000	-0.5000000

梯度法小结

- 梯度法是从梯度的几何含义自然延伸得到的

所以几何上比较直观

- 梯度法的基本思想:

从当前点 \mathbf{x}_k 出发寻找使得目标函数下降最快的方向,

即负梯度方向。

- 优点: 迭代点列总是收敛的, 而且计算过程简单



梯度法的缺点

- 梯度法相邻的两个搜索方向是相互垂直的，
迭代点越靠近极小值点则函数下降的速度越慢
- 对于 N 变量函数 $f(x_1, x_2, \dots, x_N)$ 而言，
收敛到一个极小值的速度可能很慢
- 一般地，函数 f 的极小值在几何上使得值 h_{\min} 很小，
这导致需要大量的极小化过程
- 梯度法一般用于最优化过程开始的几步搜索



目 录

- 单变量函数的极小值
- 内德-米德方法（单纯形法）
- 最速下降法（梯度方法）
- 牛顿方法



牛顿方法原理

- 由单变量函数的二次逼近求极小值的方法推广而得，以有 N 个独立变量的二次多项式的极小值来近似代替目标函数 f 的极小值
- 对有 N 个独立变量的函数 $z=f(x_1, x_2, \dots, x_N)$ 而言，从初始点 P_0 开始，递归构造出一个含 N 个变量的二次多项式序列
- 如果目标函数是良态的，并且初始点在实际极小值附近，则该二次多项式的极小值序列将收敛到目标函数 f 的极小值

黑森 (HESSIAN) 矩阵

- 定义8.5 设 $z=f(X)$ 是 X 的函数, 对于 $i, j=1, 2, \dots, N$,

$$\frac{\partial^2 f(X)}{\partial x_i \partial x_j}$$

存在。 f 在 X 处的黑森矩阵是一个 $N \times N$ 矩阵

$$Hf(X) = \left[\frac{\partial^2 f(X)}{\partial x_i \partial x_j} \right]_{N \times N}$$

其中, $i, j=1, 2, \dots, N$



例8.10

求函数 $f(x, y) = \frac{x - y}{x^2 + y^2 + 2}$ 在点 $(-3, -2)$ 处的黑森矩阵

$$\text{解: } f_x(x, y) = \frac{-x^2 + 2xy + y^2 + 2}{(x^2 + y^2 + 2)^2}$$

$$f_y(x, y) = \frac{-x^2 - 2xy + y^2 - 2}{(x^2 + y^2 + 2)^2}$$



二阶偏导数为

$$f_{xx}(x, y) = \frac{2(x^3 - 3x^2y - 3x(y^2 + 2) + y(y^2 + 2))}{(x^2 + y^2 + 2)^3}$$

$$f_{xy}(x, y) = \frac{2(x^3 + 3x^2y + x(2 - 3y^2) - y(y^2 + 2))}{(x^2 + y^2 + 2)^3}$$

$$f_{yx}(x, y) = \frac{2(x^3 + 3x^2y + x(2 - 3y^2) - y(y^2 + 2))}{(x^2 + y^2 + 2)^3}$$

$$f_{yy}(x, y) = -\frac{2(2x + x^3 - 6y - 3x^2y - 3xy^2 + y^3)}{(x^2 + y^2 + 2)^3}$$

在 $(x, y) = (-3, -2)$ 处求黑森矩阵

$$Hf(x, y) = \begin{bmatrix} f_{xx}(x, y) & f_{xy}(x, y) \\ f_{yx}(x, y) & f_{yy}(x, y) \end{bmatrix}$$

得

$$Hf(-3, -2) = \frac{1}{3375} \begin{bmatrix} 138 & -78 \\ -78 & -122 \end{bmatrix}$$


二阶泰勒多项式

- 定义8.6 $f(X)$ 在中心 A 处的二阶泰勒多项式为

$$Q(X) = f(A) + \nabla f(A) \cdot (X - A)^T + \frac{1}{2} (X - A) Hf(A) (X - A)^T$$

- 设 $z=f(x_1, x_2, \dots, x_N)$ 的一阶和二阶偏导数存在，并在包含 P_0 的一个区间内连续， f 在点 P 处有极小值。

则 f 在 P_0 的泰勒展开为

$$Q(X) = f(P_0) + \nabla f(P_0) \cdot (X - P_0)^T + \frac{1}{2} (X - P_0) Hf(P_0) (X - P_0)^T$$


二阶泰勒多项式

- $Q(X)$ 是一个 N 变量的二阶多项式，它可能在

$\nabla Q(X)=0$ 有极小值

- 由 $\nabla Q(X)=0$ 得

$$Q(X) = f(P_0) + \nabla f(P_0) \cdot (X - P_0)^T + \frac{1}{2} (X - P_0) Hf(P_0) (X - P_0)^T$$

$$\nabla Q(X) = \nabla f(P_0) + (X - P_0) (Hf(P_0))^T = 0$$

- 若 P_0 在点 P （ f 的极小值点）附近，则 $Hf(P_0)$ 可逆，

则：可求得 $X = P_0 - \nabla f(P_0) (Hf(P_0))^{-1}^T$



$$\nabla Q(\mathbf{X}) = \nabla f(\mathbf{P}_0) + (\mathbf{X} - \mathbf{P}_0)(\mathbf{H}f(\mathbf{P}_0))^T = 0$$

$$(\mathbf{X} - \mathbf{P}_0)(\mathbf{H}f(\mathbf{P}_0))^T = -\nabla f(\mathbf{P}_0)$$

$$(\mathbf{X} - \mathbf{P}_0) = -\nabla f(\mathbf{P}_0)((\mathbf{H}f(\mathbf{P}_0))^{-1})^T$$

可得: $\mathbf{X} = \mathbf{P}_0 - \nabla f(\mathbf{P}_0)((\mathbf{H}f(\mathbf{P}_0))^{-1})^T$

■ 用 \mathbf{P}_1 代替上式中的 \mathbf{X} ,

$$\mathbf{P}_1 = \mathbf{P}_0 - \nabla f(\mathbf{P}_0)((\mathbf{H}f(\mathbf{P}_0))^{-1})^T$$

■ 用 \mathbf{P}_{k-1} 代替 \mathbf{P}_0 , \mathbf{P}_k 代替 \mathbf{P}_1 , 得

$$\mathbf{P}_k = \mathbf{P}_{k-1} - \nabla f(\mathbf{P}_{k-1})((\mathbf{H}f(\mathbf{P}_{k-1}))^{-1})^T$$



$$\mathbf{P}_k = \mathbf{P}_{k-1} - \nabla f(\mathbf{P}_{k-1})((\mathbf{H}f(\mathbf{P}_{k-1}))^{-1})^T$$

- 上式建立了一个迭代关系式，由此迭代关系式可生成点序列 $\{\mathbf{P}_k\}(k=0,1,2,\dots)$
- 但算法中涉及到矩阵求逆的运算，理论上虽然可行，实际上用它进行计算则效率很低



改进的牛顿方法概要

■ 设 P_k 已知

➤ 计算搜索方向

$$S_k = -\nabla f(P_{k-1})((Hf(P_{k-1}))^{-1})^T$$

➤ 在区间 $[0, b]$ 上对 $\Phi(\gamma)=f(P_k+\gamma S_k)$ 进行单变量极小化, b 为较大值。得到值 $\gamma=h_{min}$

它是 $\Phi(\gamma)$ 的极小值点。

关系式 $\Phi(h_{min})=f(P_k+h_{min}S_k)$ 表明,

它是 $f(X)$ 沿搜索线 $X=P_k+h_{min}S_k$ 的一个极小值



改进的牛顿方法概要

- 构造下一点, $P_{k+1} = P_k + h_{min} S_k$
- 进行终止条件测试, $\|f(P_{k+1}) - f(P_k)\| < \varepsilon$
 $\|P_{k+1} - P_k\| < \varepsilon$

即函数值 $f(P_k)$ 和 $f(P_{k+1})$ 是否足够相近,

距离 $\|P_{k+1} - P_k\|$ 是否足够小?

■ 重复上述过程



无约束优化方法——直接法总结

Nelder-Mead法（单纯形法）

思路清楚，收敛慢



无约束优化方法——间接法总结

1 梯度法

- 方向： 负梯度，用到一阶导数
- 适合于精度不高或用于复杂函数寻找一个好的初始点

2 牛顿法

- 用到一阶导数和海色矩阵，具有二次收敛性
- 要求海色矩阵非奇异，且维数不宜太高



作业

P342 8.2.4 2

P352 4,5,6

报告：单纯形法程序，梯度法程序，牛顿法程序

要求：每个程序分为测试主程序**main**和具体函数程序，**main**函数里面包含测试算例所有内容。

比如牛顿法程序：**main.m, Newton.m**

